



Как мы делали MLOps с нуля



Михаил Каменщиков

руководитель юнита Рекомендаций

- в Авито с 2016 года
- все это время занимаюсь развитием рекомендаций (сначала как DS инженер, а последние 3 года как менеджер)
- tg: @greenwo1f



План презентации

Введение: наши задачи, что такое MLOps	04
Airflow	10
ML Flow	18
Model Registry	25
Планы на будущее	31

Немного истории

1


2

3

4

Персональные рекомендации в Авито

- первое, что видит пользователь, заходя на Авито
- более 50% просмотров и более 30% контактов
- зоопарк ML моделей и микросервисов (>20)
- много данных и большие нагрузки (10кк rpm в самое нагруженное хранилище и редис с историей на 2ТБ)
- 8 лет развития с нуля



Сколько у нас данных?

220 млн

объявлений

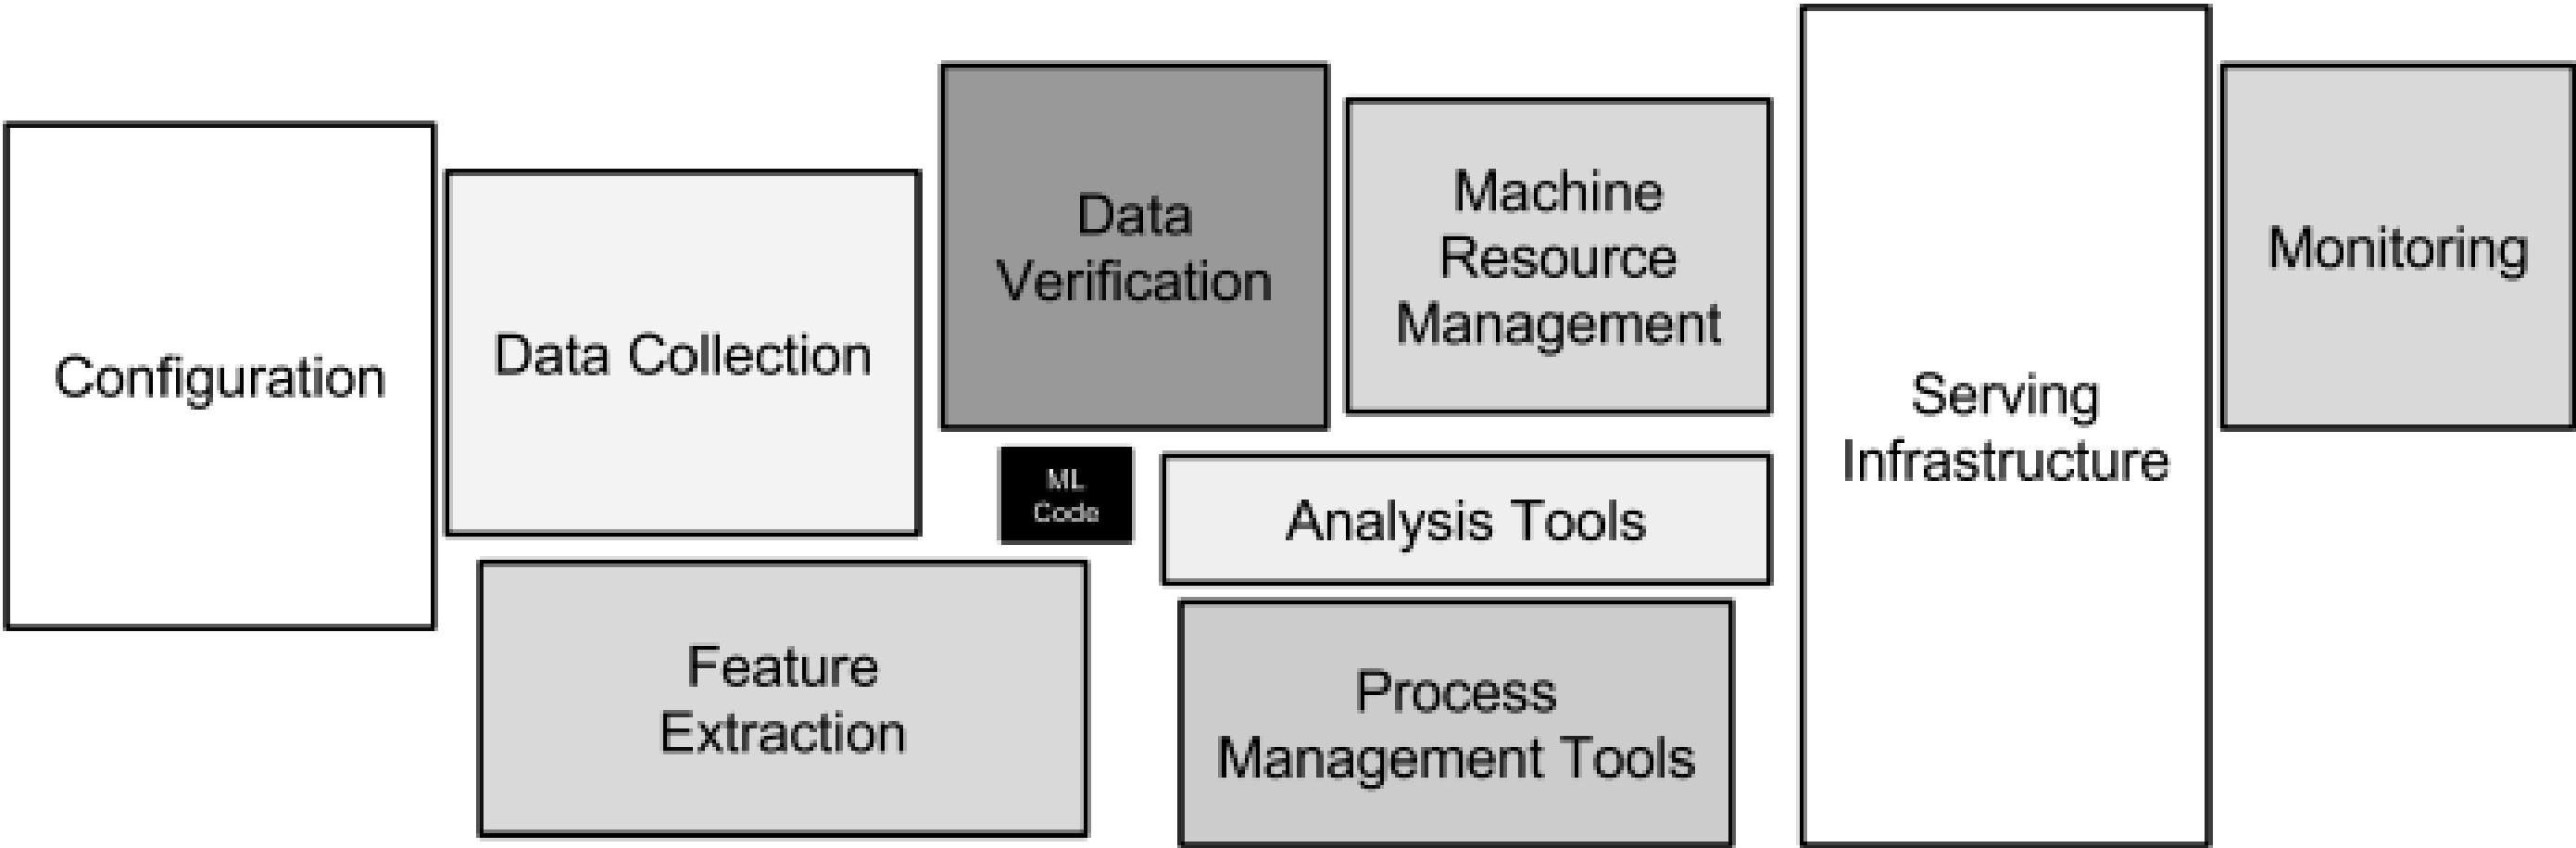
20 млн

пользователей ежедневно

500 млн

действий в сутки

Что такое MLOps?



Что такое MLOps?



ML + Ops. как DevOps, только для ML.



Развертывание моделей. Облегчение доставки моделей машинного обучения до продакшена, контейнеризация



Эксперименты. Важно обеспечить воспроизводимость экспериментов, а так же хранить их результаты



Данные. Подготовка датасетов, хранение, версионирование



Мониторинг. В случае ML нам важны не только технические метрики, но и метрики качества



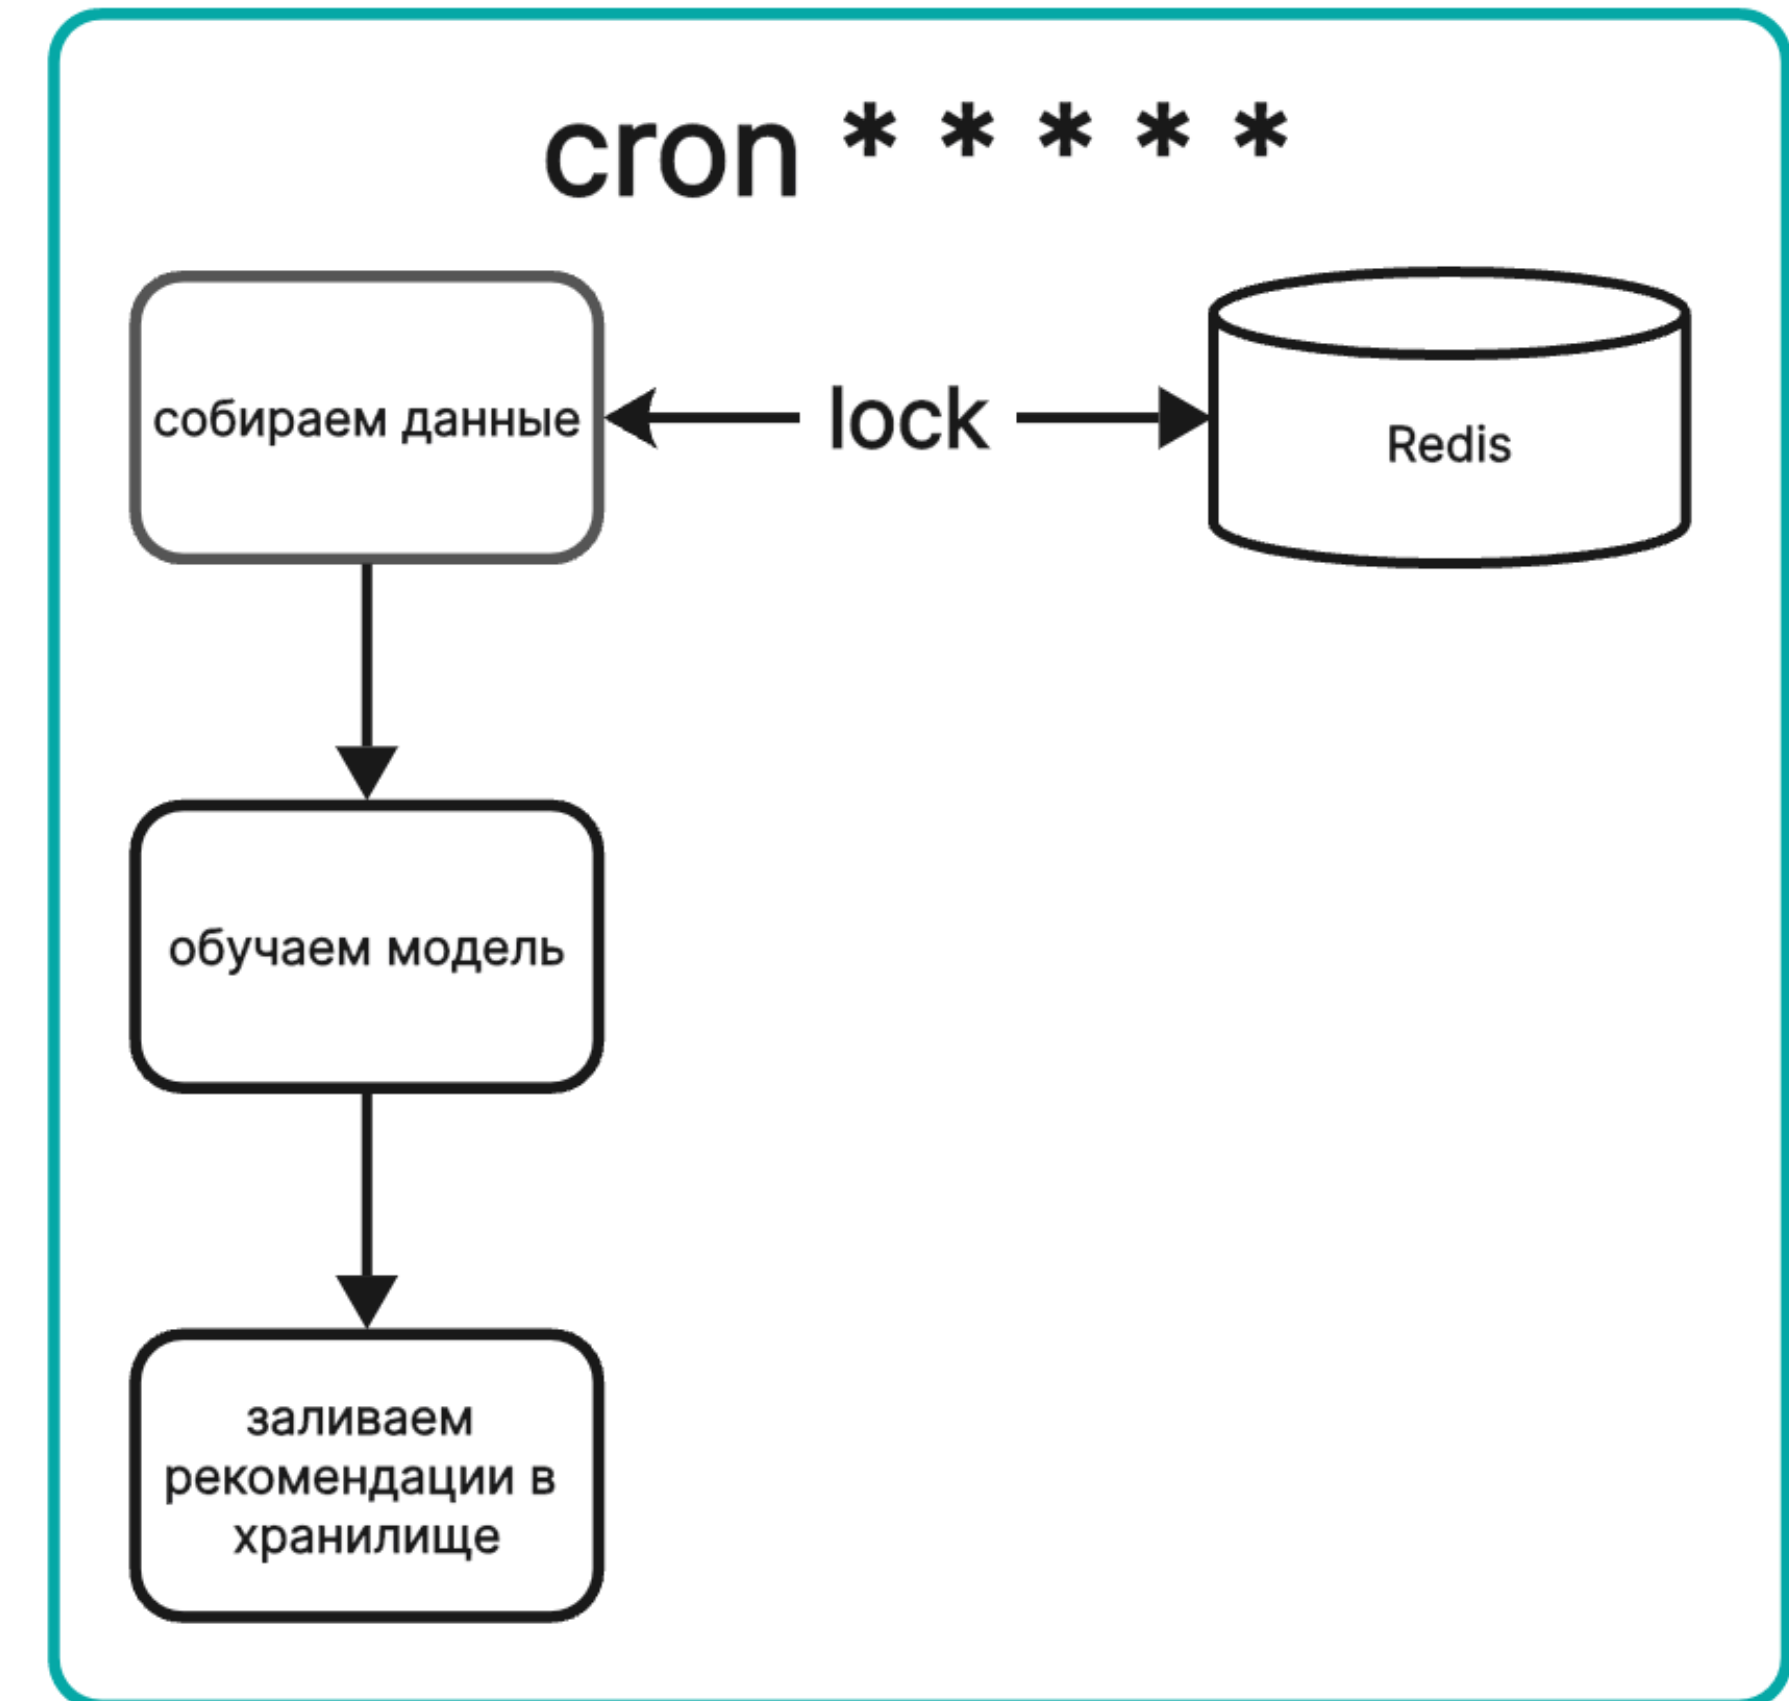
Совместная работа. Общая платформа для DS инженеров, где можно проводить эксперименты, переиспользовать наработки коллег

Collab

или наша самая первая модель рекомендаций

1. собираем данные о кликах пользователей
2. обучаем модель + формируем рекомендации
3. заливаем их в key-value хранилище

- запускаем все по крону на своих машинках
- код деплоим через скрипт `deploy.sh`



эра Airflow



Предпосылки

- стало появляться больше моделей и больше машинок - тяжело за всем следить
- команда стала больше
- участились инциденты
- рекомендации стали более важным и чувствительным к проблемам компонентом
- не было единого способа сделать регулярный пайплайн, каждый делал как умел
- насмотрелись на PaaS и захотели так же

Что мы хотим?

- запускать все в контейнерах на кластере (чтобы не было проблем с зависимостями)
- управлять ресурсами и эффективно их утилизировать
- деплоить «по кнопке», как сервисы в PaaS
- чтобы все пайплайны «жили» в одном месте и можно было их мониторить
- чтобы один и тот же код использовался для экспериментов и прода

Что такое Airflow




Scalable

Airflow™ has a modular architecture and uses a message queue to orchestrate an arbitrary number of workers.
Airflow™ is ready to scale to infinity.



Dynamic

Airflow™ pipelines are defined in Python, allowing for dynamic pipeline generation. This allows for writing code that instantiates pipelines dynamically.



Extensible

Easily define your own operators and extend libraries to fit the level of abstraction that suits your environment.



Elegant

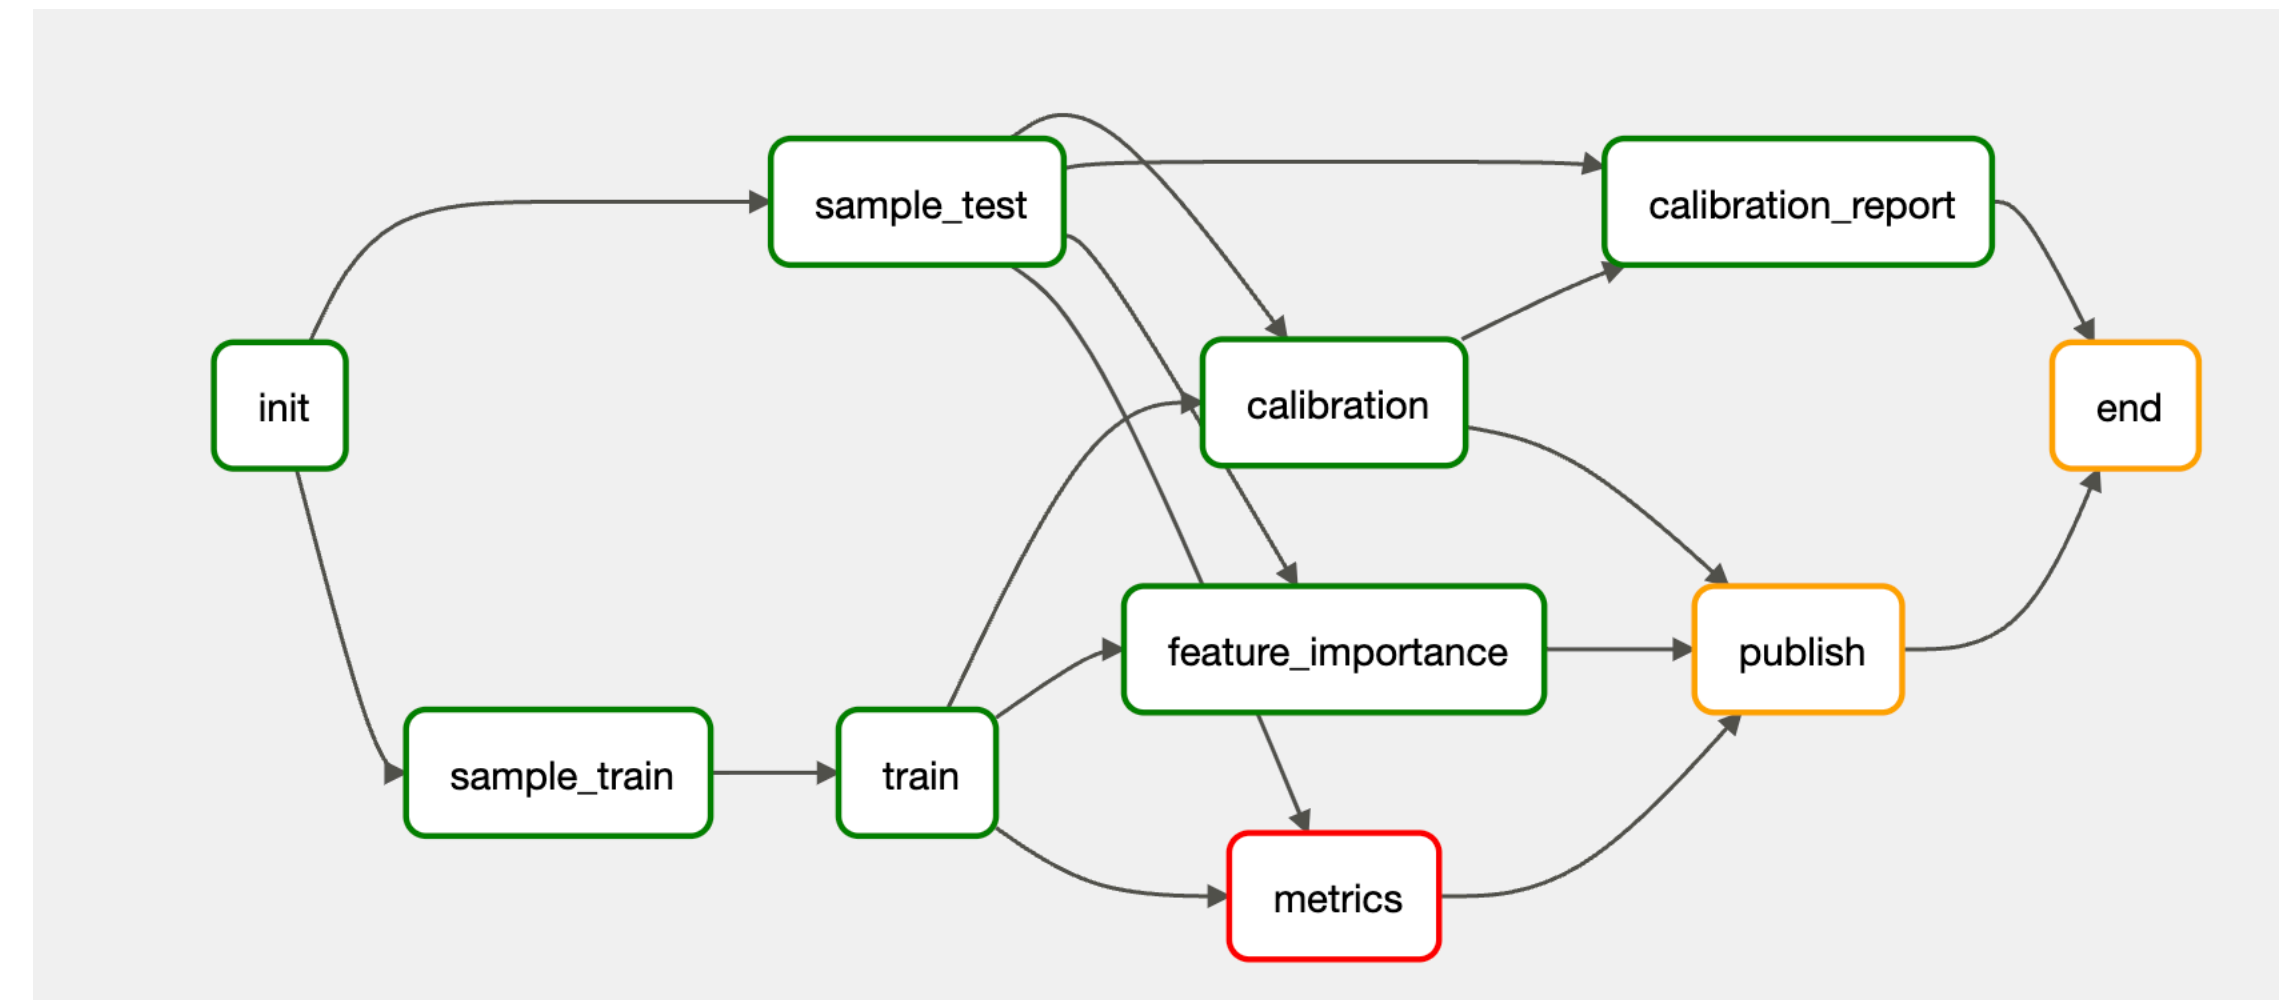
Airflow™ pipelines are lean and explicit. Parametrization is built into its core using the powerful Jinja templating engine.

короче

Airflow - это фреймворк для запуска пайплайнов. Не обязательно ML.

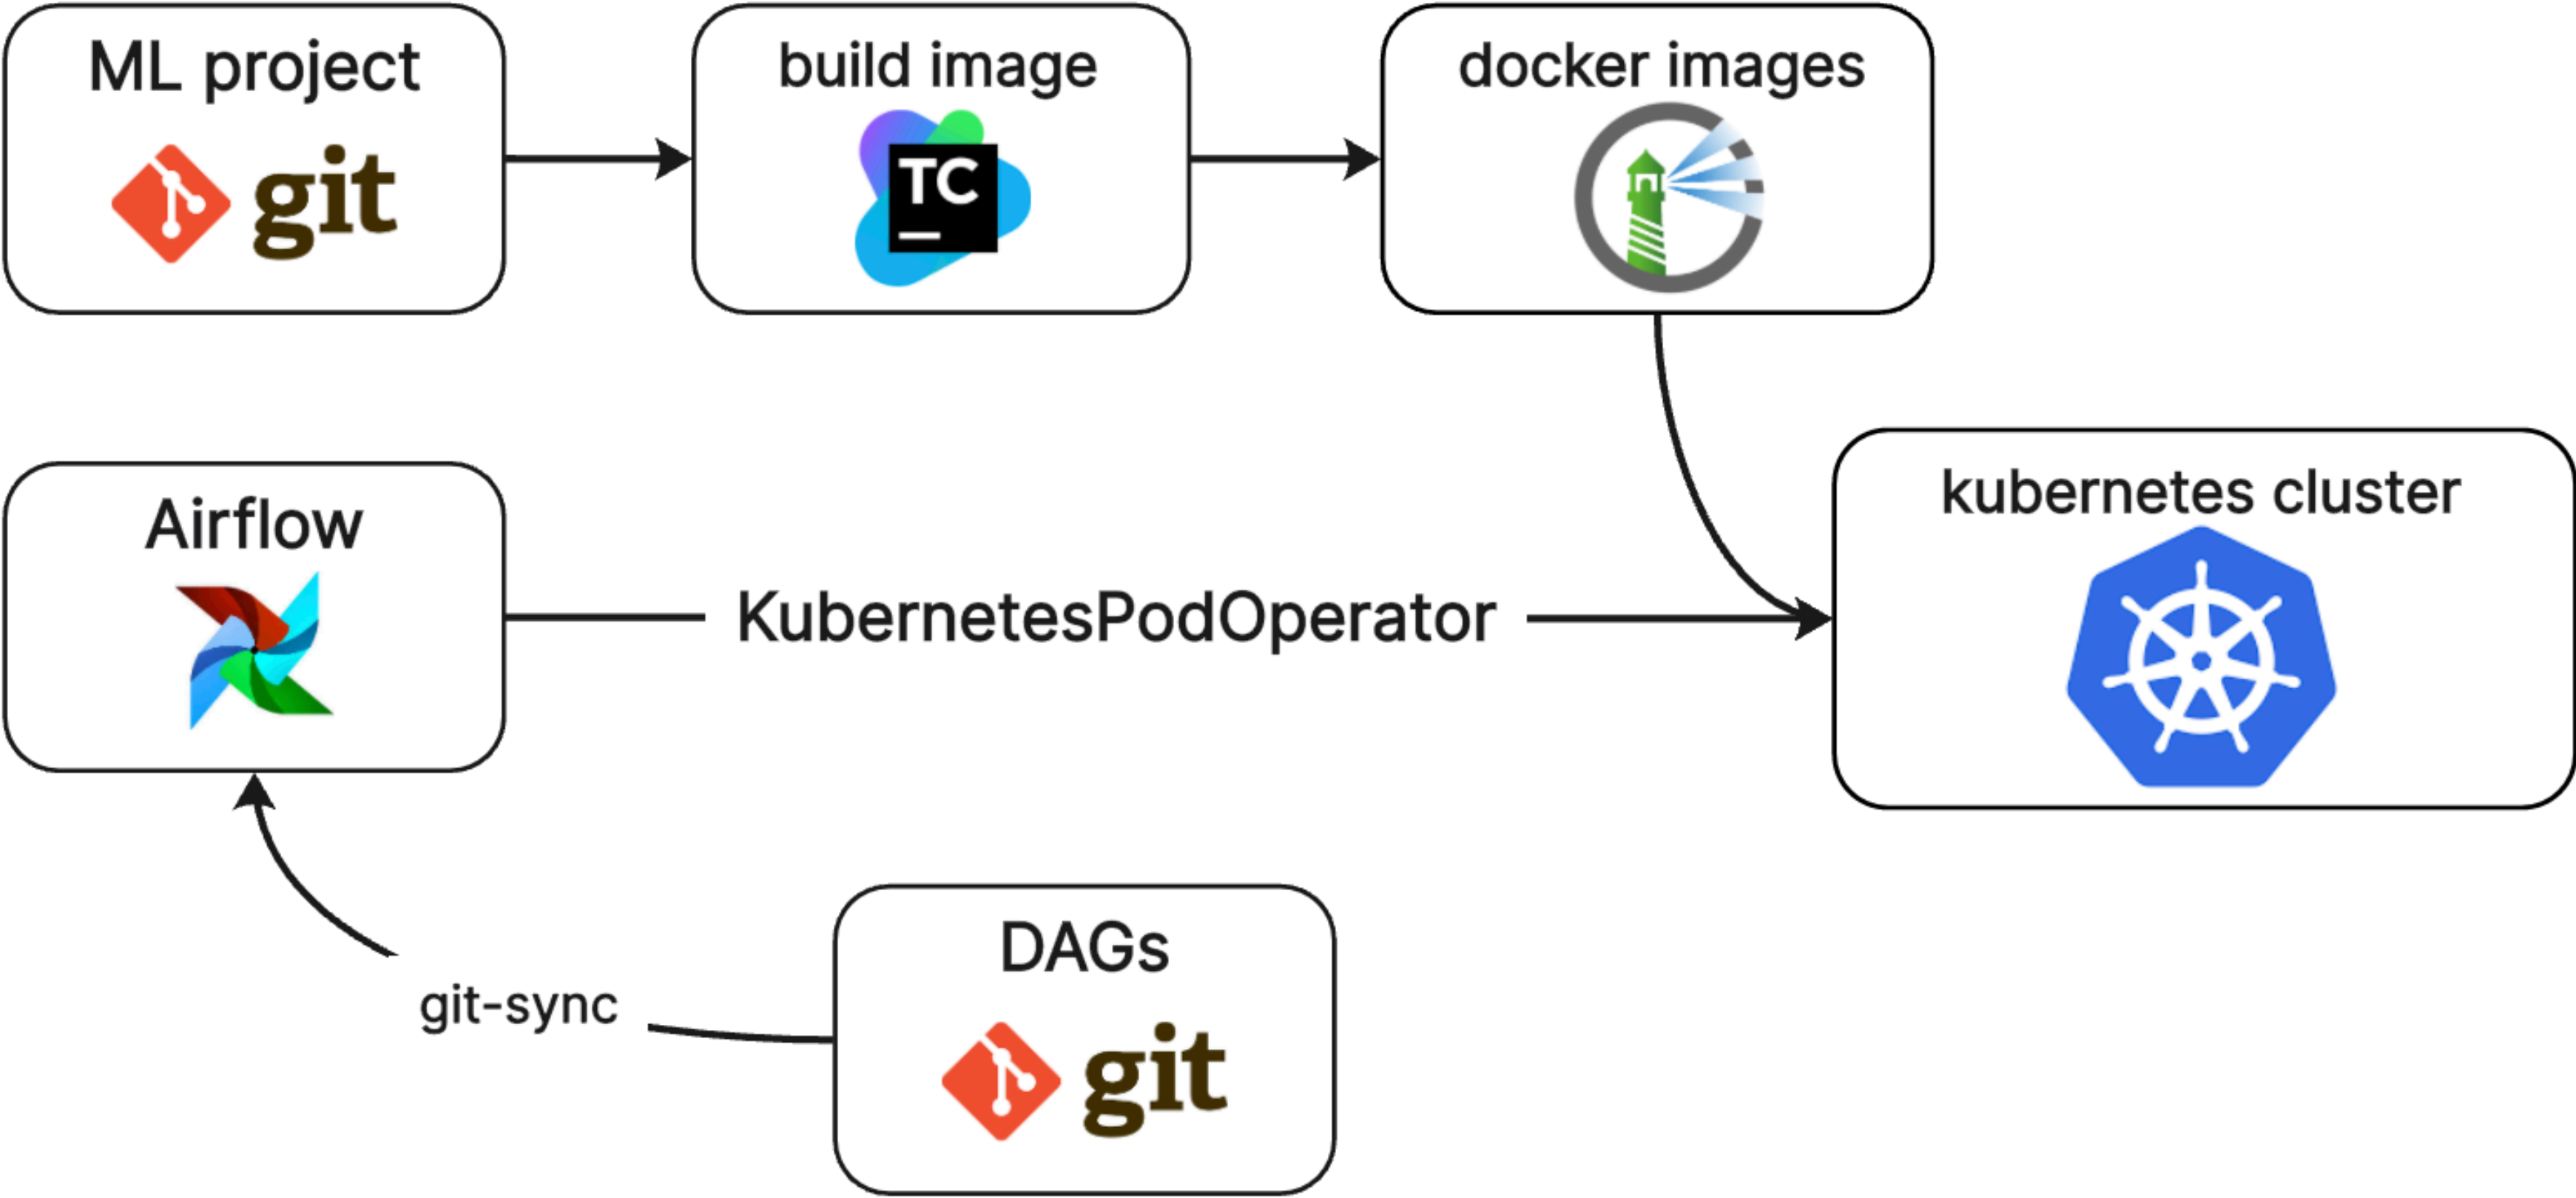
Пайплайн в Airflow

- **DAG** - Directed Acyclic Graph
- в Airflow вершинами графа являются операторы
- **оператор** - это некоторая программа (может быть на bash, Python, докер образ)
- можем указывать любую зависимость между операторами
- а также, передавать данные между операторами через механизм **XCom** (не игра)



```
t1 = BashOperator(  
    task_id="print_date",  
    bash_command="date",  
)  
  
t2 = BashOperator(  
    task_id="sleep",  
    depends_on_past=False,  
    bash_command="sleep 5",  
    retries=3,  
)
```

Как подружить Airflow + k8s



Что нам дал переход на Airflow

- ускорение пайплайна и рост продуктовых метрик за счет этого (на **8%** вырастили метрики модели **Collab** за счет ускорения цикла с **5 до 1.5 часов**)
- деплой «по кнопке»
- упростились АБ тесты - теперь можно просто создать новую версию ДАГа с другим образом
- существенно снизилось число инцидентов
- появился стандарт для новых проектов, где нужны регулярные пайплайны

Наш Airflow в цифрах

7

проектов

100+

DAGов

1000+


запусков в день

ML Flow



Воспроизводимость экспериментов

- невозпроизводимые эксперименты не имеют ценности
- если результаты хранятся только у вас в голове, то никто не сможет ими воспользоваться
- даже вы сами через некоторое время



Трекинг экспериментов

большая часть ML экспериментов - это различные изменения

гиперпараметров, например:

- даты, за которые собираем датасет
- различные способы предобработки данных
- параметры модели (количество деревьев, learning rate)
- признаки, которые используем в модели

а результаты эксперимента – это:

- метрики
- различные артефакты (модели, картинки, примеры работы)



Что такое ML Flow?

по сути, это БД + API + UI

- ML Flow решает задачу **трекинга** экспериментов, **но не воспроизводимости**
- можно логировать параметры, метрики, артефакты
- для устоявшихся пайплайнов формат зафиксирован, чтобы можно было сравнивать запуски

```
import os
import json
import mlflow

tracking_uri = 'https://prod.k.avito.ru/service-rec-models/'
experiment_name = 'new_experiment_name'
params = {'param': 1}
metrics = {'AUC': 0.23}
local_artifact_path = 'artifact.json'

mlflow.set_tracking_uri(tracking_uri)
mlflow.create_experiment(experiment_name)

with mlflow.start_run(
    run_name = "Example_run",
    description = "example description"
) as r:

    mlflow.log_params(params)
    mlflow.log_artifact(local_artefact_path, )
    mlflow.log_metrics(metrics, step=1)
```


Как сейчас выглядят наши эксперименты

TableChartEvaluationExperimental

				Metrics		Parameters			
<input type="checkbox"/>	<input type="checkbox"/>	Run Name	Created	Duration	average_precision		learning_rate	num_iterations	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>masked-lynx-621</div>	<div><div></div>1 year ago</div>	124ms	0.9557010164407802		0.0161238...	2679	<div><div></div></div> <div>Show more columns (18 total)</div>
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>monumental-bird-393</div>	<div><div></div>1 year ago</div>	101ms	0.9555982319122476		0.0179618...	2991	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>efficient-carp-111</div>	<div><div></div>1 year ago</div>	124ms	0.9554988300926176		0.0126972...	2466	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>sneaky-fox-183</div>	<div><div></div>1 year ago</div>	100ms	0.9554085615585044		0.0101558...	2984	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>casual-newt-824</div>	<div><div></div>1 year ago</div>	116ms	0.9552676056537011		0.0178975...	2566	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>trusting-robin-546</div>	<div><div></div>1 year ago</div>	105ms	0.9551674041836182		0.0103712...	2922	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>salty-dolphin-794</div>	<div><div></div>1 year ago</div>	104ms	0.9548612280538475		0.0101460...	2479	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>calm-mink-837</div>	<div><div></div>1 year ago</div>	111ms	0.9546970917032079		0.0354376...	2269	
<input type="checkbox"/>	<input type="checkbox"/>	<div><div></div>resilient-sloth-812</div>	<div><div></div>1 year ago</div>	104ms	0.9544813378600552		0.0162752...	2687	

А что нужно для воспроизводимости?



Что нам дало внедрение MLFlow

- появилось единое место для записи результатов экспериментов
- есть возможность делиться результатами по ссылке (важно!)
- хранится история всех экспериментов
- суммарно в базе более 200 экспериментов и более 1000 разных запусков

Model Registry



Проблемы, которые мы решали

1) чтобы выкатить новую модель в прод и запустить АБ тест, нужно потратить время на:

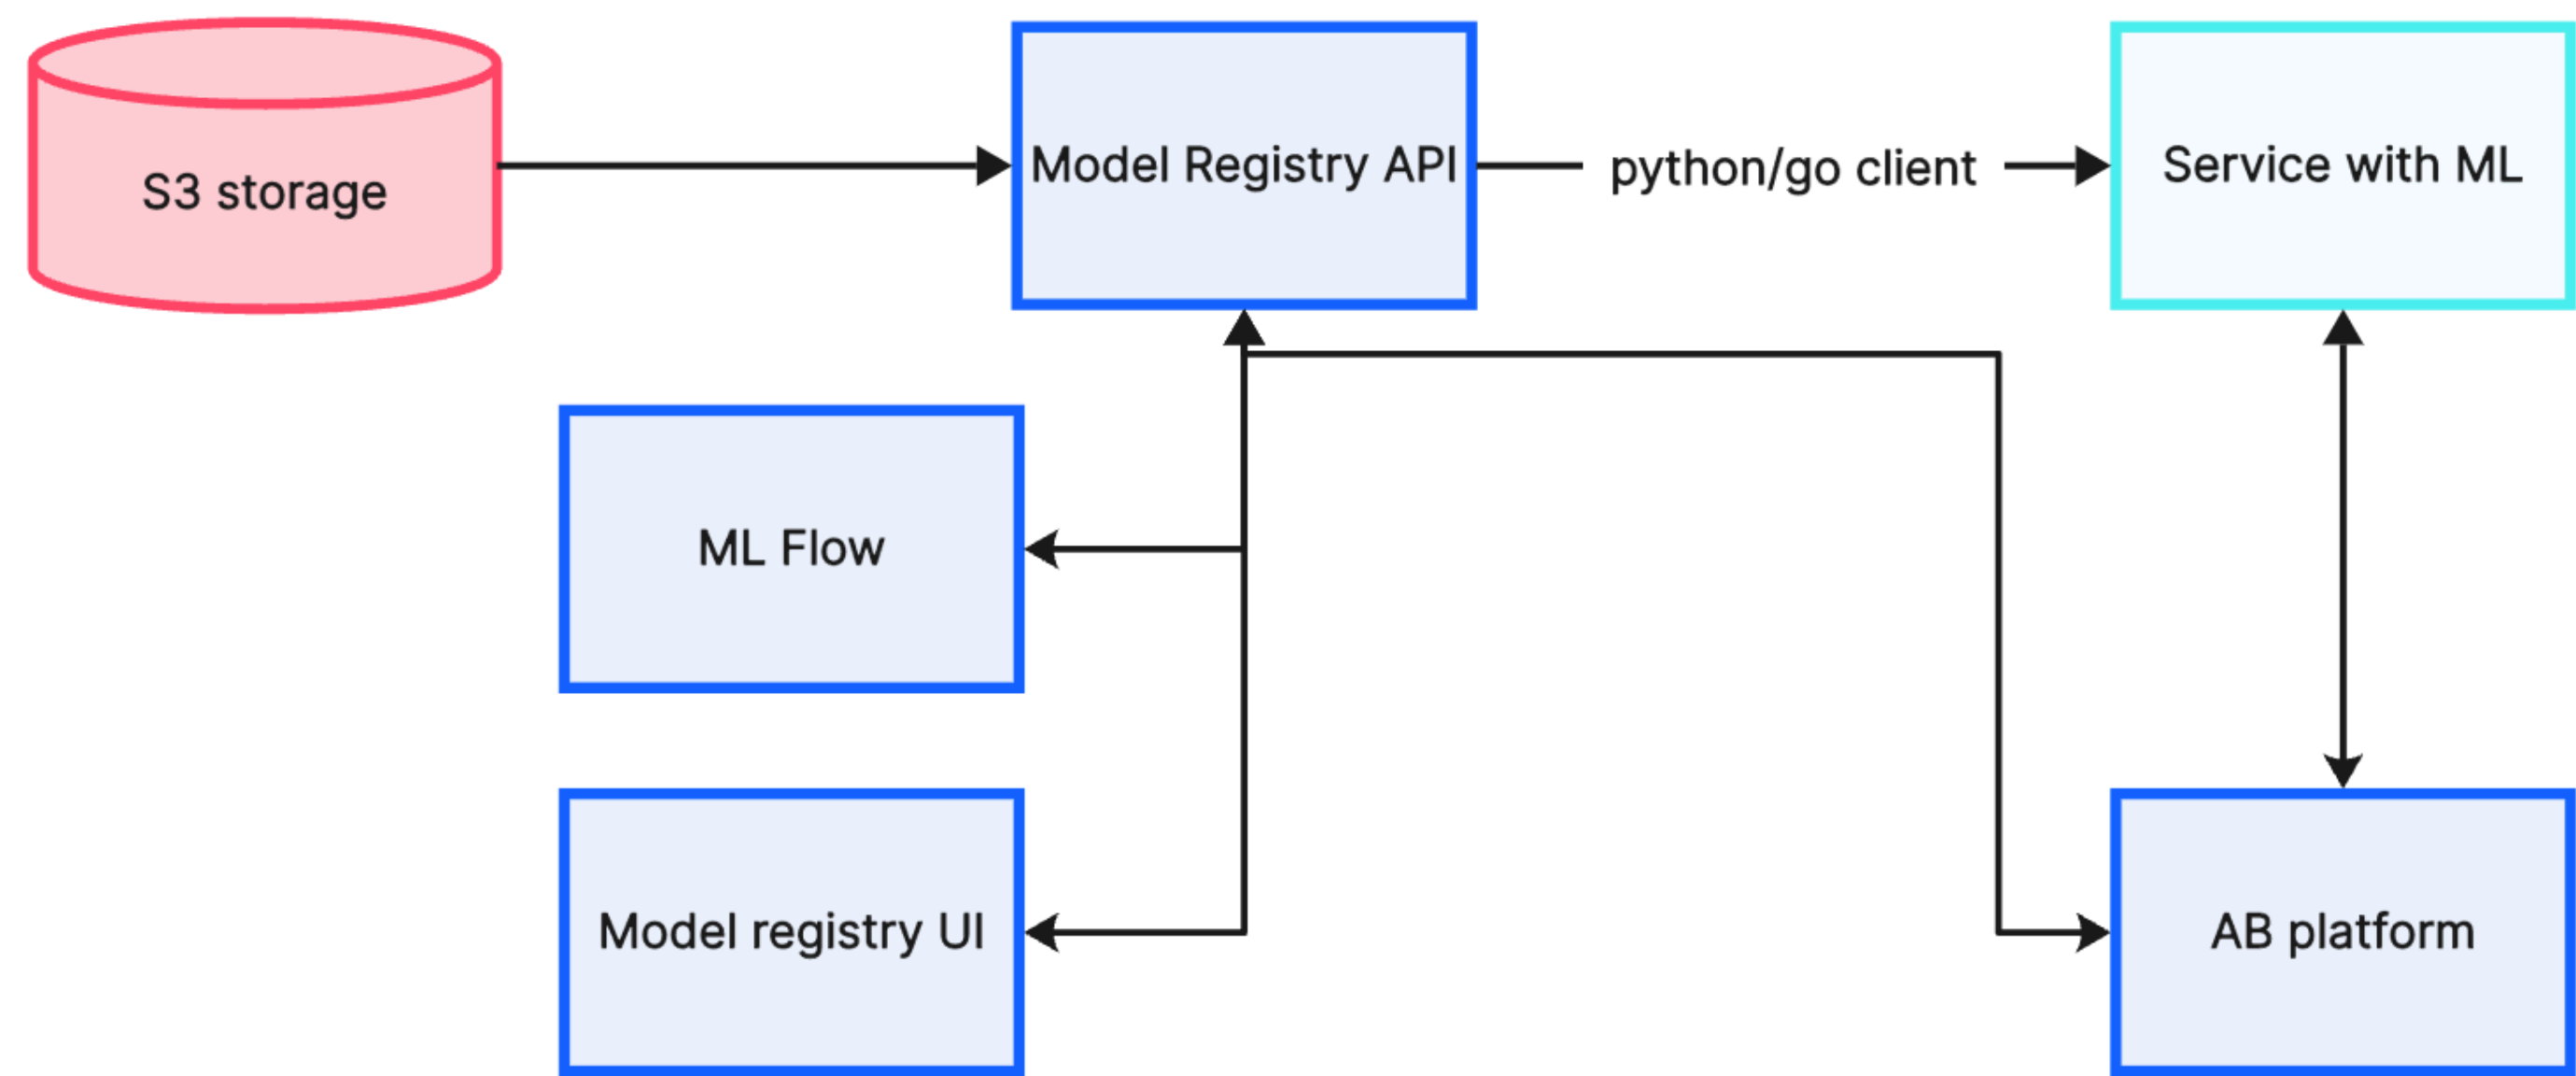
- code review (от 10 минут до +inf)
- билды и тесты в CI/CD (10-30 минут)
- выкатить сервис (10-15 минут)

а также не ошибиться, вручную перенося названия групп из АБ платформы


2) непонятно, откуда модель взялась (нет ссылок на эксперимент, метрики)

Model Registry

Микросервис, который хранит метаданные о моделях и умеет отдавать их по API из S3



Model Registry UI

Версия	Время загрузки	Статус	АБ лейбл	АБ группа	Статус доставки
2	22/03/24 15:25:21	ab	<div>ranker_recent_searches_engine</div> <div>time_since</div>	<div>fresh ×</div> <div>prod_ranker ×</div>	<div>rec-representation-go</div> <div>rec-representation-go-local</div> <div>225 / 225</div> <div>1 / 1</div>
1	 28/02/24 01:13:53	prod	<div>ranker_recent_searches_engine</div> <div>ranker_recent_searches_engine</div> <div>ranker_item2vec_main_page</div>	<div>fresh ×</div> <div>fresh ×</div> <div>item2vec_alt ×</div>	<div>rec-representation-go</div> <div>rec-representation-go-local</div> <div>225 / 225</div> <div>1 / 1</div>

Что нам дало Model Registry

- время для запуска типового АБ теста сократилось с **2 часов** до **15 минут**
- есть место, где хранятся все модели - можно скачать их и проанализировать
- можно найти результаты экспериментов для модели из АБ теста
- используется в 4 DS командах

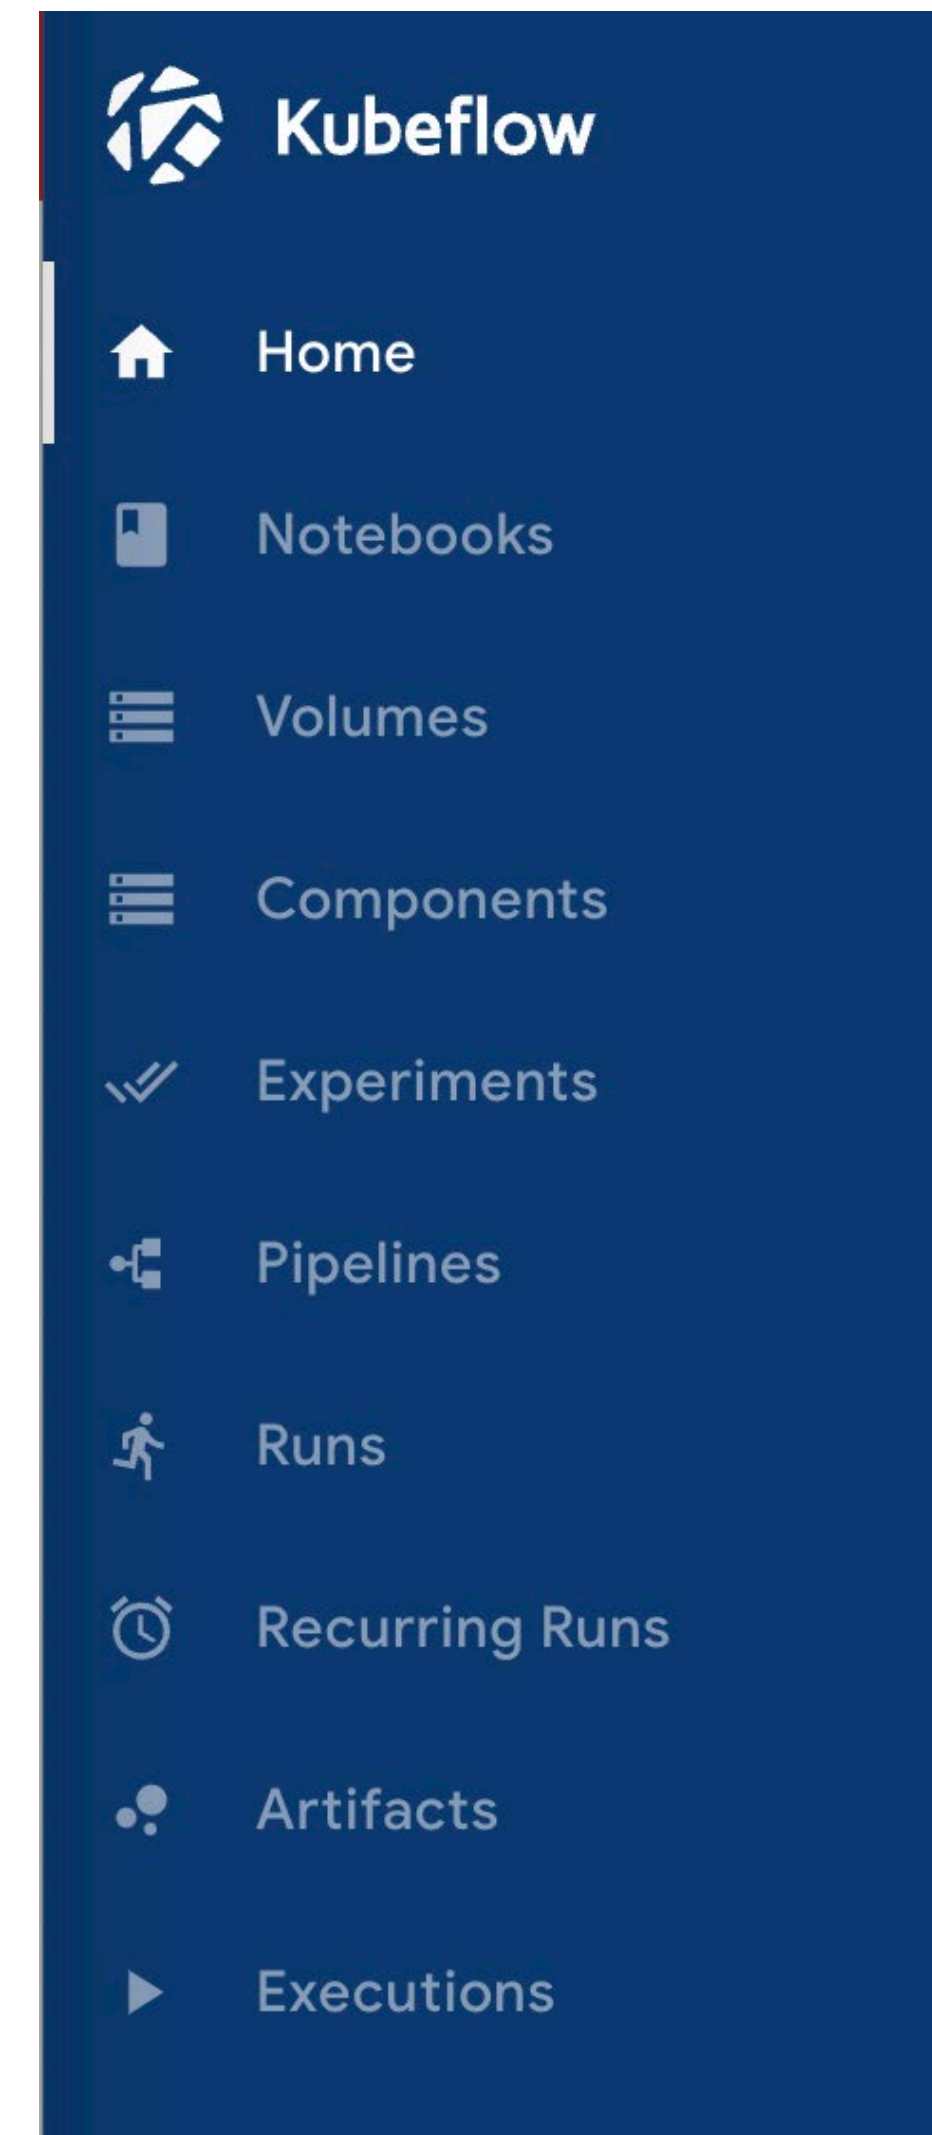
Что в итоге

- существенно упростили запуск сложных пайплайнов с Airflow
- облегчили жизнь десяткам DS с MLFlow
- снизили time to market с Model Registry

Что дальше?

Полгода назад появилась отдельная команда **ML Platform**.
мы продолжаем развивать текущие инструменты и делаем новую платформу на базе **Kubeflow**,
в которой будет фокус на:

- воспроизводимых экспериментах
- переиспользовании компонент
- эффективной утилизации железа, не только для продакшена, но и для ad-hoc экспериментов





спасибо!

**следите за
обновлениями :)**